Parcial 1: Teoría de Aprendizaje de Máquinas

2026-2

Tema:

Métodos kernel, espacios de características y formulación matricial

Profesor:

Diego Armando Pérez Rosero

Estudiantes:

Hernán Jair Telpiz Cuarán

Marlyn Nathalia Mora Riascos

16 de octubre de 2026

Marco General y Notación Matricial

Preámbulo del Problema 1

Sea un conjunto de datos i.i.d. $\{(x_n, t_n)\}_{n=1}^N$ con $x_n \in \mathbb{R}^P$, $t_n \in \mathbb{R}$ y mapeo determinístico a un espacio de características $\phi : \mathbb{R}^P \to \mathbb{R}^Q$:

$$t_n = \phi(x_n)^\top w + \eta_n, \quad w \in \mathbb{R}^Q, \quad \eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2).$$

Agrupando las N observaciones en forma compacta:

$$t = \Phi w + \eta,$$

donde:

- $t = [t_1, t_2, \ldots, t_N]^\top \in \mathbb{R}^{N\times 1}$: vector de respuestas observadas.
- $\Phi = [\phi(x_1), \ldots, \phi(x_N)]^\top \in \mathbb{R}^{N\times Q}$: matriz de diseño de características.
- $w = [w_1, w_2, \ldots, w_Q]^\top \in \mathbb{R}^{Q\times 1}$: vector de parámetros a estimar.
- $\eta = [\eta_1, \eta_2, \ldots, \eta_N]^\top \in \mathbb{R}^{N\times 1}$: vector de perturbaciones, $\eta \sim \mathcal{N}(\mathbf{0}, \sigma_\eta^2 I_N)$.

Punto 1.1

Enunciado 1.1: Mínimos Cuadrados

1.1 Mínimos cuadrados. Plantee la función objetivo y deduzca, paso a paso, el estimador por mínimos cuadrados, incluyendo las condiciones necesarias para la existencia y unicidad de la solución.

Planteamiento de la Función Objetivo

Sean $t \in \mathbb{R}^{N\times 1}$ el vector de observaciones, $\Phi \in \mathbb{R}^{N\times Q}$ la matriz de diseño y $w \in \mathbb{R}^{Q\times 1}$ el vector de parámetros. El criterio geométrico de Mínimos Cuadrados Ordinarios (OLS) busca el vector de pesos $\hat{w}_{\text{OLS}} \in \mathbb{R}^Q$ que minimice la norma euclídea al cuadrado del vector de error residual $e(w) = t - \Phi w \in \mathbb{R}^{N\times 1}$:

$$\min_{w\in\mathbb{R}^Q} J(w) = \|e(w)\|_2^2 = \|t - \Phi w\|_2^2 = (t - \Phi w)^\top (t - \Phi w).$$

Expansión Matricial Paso a Paso

Aplicando la propiedad de la transpuesta de un producto $(\Phi w)^\top = w^\top \Phi^\top$ y distribuyendo término a término:

$$\begin{aligned} J(w) &= (t^\top - w^\top \Phi^\top)(t - \Phi w) \\ &= \underbrace{t^\top t}_{1\times 1} - \underbrace{t^\top \Phi w}_{1\times 1} - \underbrace{w^\top \Phi^\top t}_{1\times 1} + \underbrace{w^\top \Phi^\top \Phi w}_{1\times 1}. \end{aligned}$$

Puesto que $t^\top \Phi w \in \mathbb{R}$ es una cantidad escalar (1×1), coincide de forma idéntica con su propia transpuesta: $(t^\top \Phi w)^\top = w^\top \Phi^\top t$. Agrupando términos semejantes:

$$J(w) = t^\top t - 2w^\top \Phi^\top t + w^\top \Phi^\top \Phi w.$$

Derivación Vectorial, Ecuaciones Normales y Despeje con la Inversa

Derivando respecto a $w \in \mathbb{R}^Q$ aplicando las identidades del cálculo matricial ($\nabla_w(\text{cte}) = \mathbf{0}$, $\nabla_w(w^\top a) = a$ y $\nabla_w(w^\top A w) = 2Aw$ con $A = \Phi^\top\Phi$ simétrica):

$$\nabla_w J(w) = \mathbf{0} - 2\Phi^\top t + 2\Phi^\top\Phi w = -2\Phi^\top t + 2\Phi^\top\Phi w.$$

Igualando el gradiente al vector nulo $\mathbf{0} \in \mathbb{R}^Q$ para hallar el punto estacionario y despejando hasta el estimador final:

$$\begin{aligned}
\nabla_w J(w) = \mathbf{0} &\implies -2\Phi^\top t + 2\Phi^\top\Phi w = \mathbf{0} \\
&\implies 2\Phi^\top\Phi w = 2\Phi^\top t \quad \big/ \div 2 \\
&\implies \Phi^\top\Phi w = \Phi^\top t \\
&\implies (\Phi^\top\Phi)^{-1}(\Phi^\top\Phi)w = (\Phi^\top\Phi)^{-1}\Phi^\top t \quad \text{(multiplicando a izquierda por la inversa)} \\
&\implies I_Q w = (\Phi^\top\Phi)^{-1}\Phi^\top t \\
&\implies \boxed{\hat{w}_{\text{OLS}} = (\Phi^\top\Phi)^{-1}\Phi^\top t}.
\end{aligned}$$

Condiciones para la Existencia y Unicidad de la Solución

1. **Existencia:** El sistema normal $\Phi^\top\Phi w = \Phi^\top t$ es siempre consistente para cualquier vector $t \in \mathbb{R}^N$.
2. **Unicidad (Existencia de la Inversa):** Para que la matriz inversa $(\Phi^\top\Phi)^{-1}$ exista y el estimador $\hat{w}_{\text{OLS}}$ sea único, la matriz $\Phi^\top\Phi \in \mathbb{R}^{Q\times Q}$ debe ser no singular ($\det(\Phi^\top\Phi) \neq 0$), lo cual exige rango columna completo:
$$\text{rango}(\Phi) = Q \quad \text{(columnas de } \Phi \text{ linealmente independientes y } N \geq Q).$$
3. **Garantía de Mínimo Global (Segundo Orden):** La matriz Hessiana es $\nabla_w^2 J(w) = 2\Phi^\top\Phi$. Bajo $\text{rango}(\Phi) = Q$, para todo $v \neq 0$ se cumple $v^\top(\Phi^\top\Phi)v = \|\Phi v\|_2^2 > 0$ ($\nabla_w^2 J(w) \succ 0$), confirmando que $\hat{w}_{\text{OLS}}$ es el único mínimo global.

Condiciones Necesarias y Suficientes de Existencia y Unicidad

1. **Independencia lineal de variables (rango$(\Phi) = Q$):** Para que la matriz $(\Phi^\top\Phi)$ se pueda invertir, su forma cuadrática debe ser estrictamente positiva para cualquier vector no nulo $v \neq 0$:
$$v^\top(\Phi^\top\Phi)v = (\Phi v)^\top(\Phi v) = \|\Phi v\|_2^2 \geq 0.$$
Al ser una norma al cuadrado, nunca es negativa. Para asegurar que sea estrictamente positiva (> 0) y evitar que el determinante sea cero, ninguna columna puede ser copia o combinación de las demás. Esto exige rango completo de columnas:
$$\text{rango}(\Phi) = Q.$$
2. **Restricción de datos suficientes ($N \geq Q$):** Como el rango no puede superar el número de filas ni de columnas ($\text{rango}(\Phi) \leq \text{mín}(N, Q)$), la condición necesaria para tener Q columnas independientes es:
$$N \geq Q.$$
Si tuviéramos menos datos que parámetros ($N < Q$), tendríamos más incógnitas que ecuaciones, la matriz sería singular ($\det(\Phi^\top\Phi) = 0$) y existirían infinitas soluciones posibles.

3. **Unicidad y mínimo global (Convexidad estricta):** Calculando la matriz Hessiana (segunda derivada del costo):

$$\nabla_w^2 J(w) = 2\Phi^\top \Phi.$$

Bajo rango completo, la Hessiana es estrictamente definida positiva en todo el espacio. Esto garantiza que la función de costo es un tazón hacia arriba (estrictamente convexa) y que el estimador es el único mínimo global.

Resultado Final: Estimador OLS

$$\hat{w}_{\text{OLS}} = (\Phi^\top \Phi)^{-1} \Phi^\top t$$

Existe y es único si y solo si la matriz Φ tiene rango de columnas completo ($\text{rango}(\Phi) = Q$), lo que exige necesariamente $N \geq Q$.

Punto 1.2

Enunciado 1.2: Mínimos Cuadrados Regularizados

1.2 Mínimos cuadrados regularizados. Formule el problema con penalización cuadrática $\lambda\|w\|_2^2$, con $\lambda > 0$, y derive su solución cerrada. Explique el efecto del parámetro de regularización.

Formulación del Problema y Expansión Matricial

Cuando la matriz $\Phi^\top \Phi$ no es invertible (debido a multicolinealidad o a que el número de características supera al de observaciones, $Q > N$), los pesos estimados por OLS se vuelven inestables o indeterminados. Para solucionar este problema mal condicionado, se introduce una penalización cuadrática sobre la magnitud de los pesos (regularización L2 o Ridge):

$$\min_{w \in \mathbb{R}^Q} J_{\text{ridge}}(w) = \|t - \Phi w\|_2^2 + \lambda \|w\|_2^2, \quad \lambda > 0.$$

Expandiendo el error residual y expresando el término de penalización como $\|w\|_2^2 = w^\top w$:

$$\begin{aligned} J_{\text{ridge}}(w) &= (t^\top - w^\top \Phi^\top)(t - \Phi w) + \lambda w^\top w \\ &= t^\top t - 2w^\top \Phi^\top t + w^\top \Phi^\top \Phi w + \lambda w^\top w. \end{aligned}$$

Derivación Analítica y Solución Cerrada

Calculando el gradiente de la función de costo regularizada respecto al vector de parámetros w:

$$\nabla_w J_{\text{ridge}}(w) = \mathbf{0} - 2\Phi^\top t + 2\Phi^\top \Phi w + 2\lambda w.$$

Igualando el gradiente al vector nulo para encontrar el punto estacionario:

$$\begin{aligned} -2\Phi^\top t + 2\Phi^\top \Phi w + 2\lambda w = \mathbf{0} &\implies 2\Phi^\top \Phi w + 2\lambda w = 2\Phi^\top t \quad \Big/ \div 2 \\ &\implies \Phi^\top \Phi w + \lambda w = \Phi^\top t. \end{aligned}$$

Como $\Phi^\top\Phi$ es matriz y λw es un vector, se introduce la matriz identidad I_Q ($\lambda w = \lambda I_Q w$) para permitir la suma matricial y factorizar w por la derecha.

$$\Phi^\top\Phi w + \lambda I_Q w = \Phi^\top t$$
$$(\Phi^\top\Phi + \lambda I_Q)w = \Phi^\top t$$
$$(\Phi^\top\Phi + \lambda I_Q)^{-1}(\Phi^\top\Phi + \lambda I_Q)w = (\Phi^\top\Phi + \lambda I_Q)^{-1}\Phi^\top t$$
$$\hat{w}_{\text{ridge}} = (\Phi^\top\Phi + \lambda I_Q)^{-1}\Phi^\top t.$$

Efecto del Parámetro de Regularización (λ)

1. **Invertibilidad Garantizada:** Para cualquier vector no nulo $v \neq \mathbf{0}$, la forma cuadrática asociada es:
$$v^\top(\Phi^\top\Phi + \lambda I_Q)v = \|\Phi v\|_2^2 + \lambda\|v\|_2^2.$$
Como $\|\Phi v\|_2^2 \geq 0$, $\lambda > 0$ y $\|v\|_2^2 > 0$, la suma es estrictamente positiva (> 0). Por lo tanto, $(\Phi^\top\Phi + \lambda I_Q)$ es siempre estrictamente definida positiva e invertible, incluso si $Q > N$.
2. **Atenuación (Encogimiento) de Coeficientes:** El hiperparámetro λ penaliza los valores grandes de los pesos, comprimiéndolos hacia cero para prevenir sobreajuste ante datos con ruido.
3. **Compromiso Sesgo-Varianza:** Introduce un pequeño sesgo controlado a cambio de reducir drásticamente la varianza del estimador, mejorando la generalización.
4. **Comportamiento Asintótico:**
$$\lim_{\lambda\to 0^+} \hat{w}_{\text{ridge}} = \hat{w}_{\text{OLS}} \quad \text{y} \quad \lim_{\lambda\to\infty} \hat{w}_{\text{ridge}} = \mathbf{0}.$$

Resultado Final — Estimador Ridge:

$$\hat{w}_{\text{ridge}} = (\Phi^\top\Phi + \lambda I_Q)^{-1}\Phi^\top t$$

Existe y es único para cualquier matriz Φ, garantizado por $(\Phi^\top\Phi + \lambda I_Q) \succ 0$.

Punto 1.3

Enunciado 1.3: Máxima Verosimilitud

1.3 Máxima verosimilitud. Bajo el supuesto de ruido gaussiano i.i.d., construya la función de verosimilitud y su logaritmo, y obtenga el estimador de w por máxima verosimilitud. Explicite su relación con mínimos cuadrados.

Planteamiento Probabilístico y Función de Verosimilitud

Asumimos que cada observación t_n se genera mediante una función lineal de las características $\phi(x_n)^\top w$ más un error o ruido aleatorio η_n:
$$t_n = \phi(x_n)^\top w + \eta_n.$$
Si el ruido sigue una distribución normal (Gaussiana) con media cero y varianza σ_η^2 de forma independiente e idénticamente distribuida ($\eta_n \sim \mathcal{N}(0, \sigma_\eta^2)$), entonces la variable t_n también se distribuye de forma

normal centrada en la predicción del modelo:

$$p(t_n \mid x_n, w, \sigma_\eta^2) = \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\right).$$

Como las N observaciones son independientes entre sí, la probabilidad conjunta de todo el vector de respuestas t (la **función de verosimilitud** en esta caso L) es el producto de las probabilidades individuales:

$$\begin{aligned} L(w, \sigma_\eta^2) = p(t \mid \Phi, w, \sigma_\eta^2) &= \prod_{n=1}^{N} p(t_n \mid x_n, w, \sigma_\eta^2) \\ &= \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\right). \end{aligned}$$

Agrupando las constantes y sumando los exponentes gracias a las leyes de las potencias:

$$L(w, \sigma_\eta^2) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2} \sum_{n=1}^{N} (t_n - \phi(x_n)^\top w)^2\right).$$

Escrito en forma matricial utilizando la norma euclídea al cuadrado del vector de error residual $t - \Phi w$:

$$L(w, \sigma_\eta^2) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2\right).$$

Función de Log-Verosimilitud

Para facilitar el cálculo y evitar lidiar con productos y exponenciales, aplicamos el logaritmo natural ln :

$$\begin{aligned} \ln L(w, \sigma_\eta^2) &= \ln\left[(2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2\right)\right] \\ &= \ln\left((2\pi\sigma_\eta^2)^{-N/2}\right) + \ln\left(\exp\left(-\frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2\right)\right). \end{aligned}$$

Utilizando las propiedades de los logaritmos ($\ln(A^B) = B \ln A$ y $\ln(\exp(u)) = u$):

$$\ln L(w, \sigma_\eta^2) = -\frac{N}{2} \ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2.$$

Obtención del Estimador por Máxima Verosimilitud ($\hat{w}_{\mathbf{MLE}}$)

El método de Máxima Verosimilitud busca el vector de pesos w que haga que los datos observados sean lo más probables posible, es decir, maximizar la log-verosimilitud:

$$\hat{w}_{\text{MLE}} = \arg\max_{w \in \mathbb{R}^Q} \left[-\frac{N}{2} \ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2\right].$$

Como el primer término no depende de w, actúa como una constante y se elimina en la optimización. Además, maximizar una expresión negativa equivale a minimizar su versión positiva:

$$\hat{w}_{\text{MLE}} = \arg\min_{w \in \mathbb{R}^Q} \left[\frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2\right].$$

Multiplicando por la constante positiva $2\sigma_\eta^2$ (la cual no cambia la ubicación del mínimo):

$$\hat{w}_{\text{MLE}} = \arg\min_{w \in \mathbb{R}^Q} \|t - \Phi w\|_2^2.$$

Rompiendo la norma euclídea al cuadrado en su forma matricial expandida:

$$\|t - \Phi w\|_2^2 = (t - \Phi w)^\top (t - \Phi w) = t^\top t - 2w^\top \Phi^\top t + w^\top \Phi^\top \Phi w.$$

Para hallar este mínimo, derivamos la función de costo respecto a w e igualamos el resultado a cero:

$$\nabla_w \left(\|t - \Phi w\|_2^2 \right) = -2\Phi^\top (t - \Phi w) = \mathbf{0}.$$

Despejando el vector w:

$$\begin{aligned} \Phi^\top (t - \Phi w) &= \mathbf{0} \\ \Phi^\top t - \Phi^\top \Phi w &= \mathbf{0} \\ \Phi^\top \Phi w &= \Phi^\top t \\ \hat{w}_{\text{MLE}} &= (\Phi^\top \Phi)^{-1} \Phi^\top t. \end{aligned}$$

Relación con Mínimos Cuadrados (OLS)

1. **Equivalencia matemática:** El estimador obtenido por Máxima Verosimilitud ($\hat{w}_{\text{MLE}}$) resulta ser exactamente idéntico a la solución analítica de Mínimos Cuadrados Ordinarios ($\hat{w}_{\text{OLS}}$).
2. **Interpretación geométrica vs. probabilística:** Mientras que OLS se plantea desde un punto de vista puramente geométrico minimizando la distancia euclídea del error sin importar de dónde provenga, Máxima Verosimilitud llega a la misma fórmula exacta partiendo de un modelo probabilístico formal bajo la hipótesis de que el ruido es Gaussiano i.i.d.

Resultado Final — Estimador MLE:

$$\hat{w}_{\text{MLE}} = (\Phi^\top \Phi)^{-1} \Phi^\top t \equiv \hat{w}_{\text{OLS}}$$

Bajo el supuesto de ruido gaussiano i.i.d., el criterio de mínimos cuadrados es formalmente equivalente al estimador de máxima verosimilitud.

Punto 1.4: Estimador Máximo a Posteriori (MAP)

Punto 1.4

Enunciado 1.4: Máximo a Posteriori

1.4 Máximo a posteriori. Suponga además el prior $w \sim \mathcal{N}(\mathbf{0}, \sigma_w^2 I_Q)$. A partir de la regla de Bayes, deduzca el problema de optimización MAP y su solución; establezca la relación entre σ_η^2, σ_w^2 y la regularización cuadrática.

1. Regla de Bayes y Densidades de Partida

Bajo el modelo $t = \Phi w + \eta$ con ruido gaussiano $\eta \sim \mathcal{N}(\mathbf{0}, \sigma_\eta^2 I_N)$, la verosimilitud de las N observaciones es:

$$p(t \mid \Phi, w) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2 \right).$$

Asumiendo un prior gaussiano con media cero y varianza idéntica sobre los Q parámetros:

$$w \sim \mathcal{N}(\mathbf{0},\, \sigma_w^2 I_Q) \implies p(w) = (2\pi\sigma_w^2)^{-Q/2} \exp\left(-\frac{1}{2\sigma_w^2}\|w\|_2^2\right).$$

Por el Teorema de Bayes, la distribución a posteriori de los pesos es:

$$p(w \mid t, \Phi) = \frac{p(t \mid \Phi, w)\, p(w)}{p(t \mid \Phi)},$$

$p(t \mid \Phi)$ es una constante positiva que no depende de w, por lo que no influye en la localización del punto óptimo.

2. Planteamiento del Problema MAP y Equivalencia con Ridge

El estimador MAP maximiza la densidad a posteriori. Dado que el logaritmo natural $\ln(\cdot)$ es una función estrictamente monótona creciente:

$$\arg\max_{w \in \mathbb{R}^Q} p(w \mid t, \Phi) = \arg\max_{w \in \mathbb{R}^Q} \ln p(w \mid t, \Phi).$$

Expandiendo el logaritmo de la posterior:

$$\begin{aligned}
\ln p(w \mid t, \Phi) &= \ln p(t \mid \Phi, w) + \ln p(w) - \ln p(t \mid \Phi) \\
&= -\frac{N}{2}\ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2 - \frac{Q}{2}\ln(2\pi\sigma_w^2) - \frac{1}{2\sigma_w^2}\|w\|_2^2 - \ln p(t \mid \Phi) \\
&= -\frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2 - \frac{1}{2\sigma_w^2}\|w\|_2^2 + C,
\end{aligned}$$

donde C absorbe los términos independientes de w. Descartando C y convirtiendo la maximización en minimización al multiplicar por la constante negativa $-2\sigma_\eta^2 < 0$:

$$\hat{w}_{\text{MAP}} = \arg\min_{w \in \mathbb{R}^Q} \left(\|t - \Phi w\|_2^2 + \frac{\sigma_\eta^2}{\sigma_w^2}\|w\|_2^2\right).$$

Comparando esta expresión con la función de costo de Ridge, $J_{\text{ridge}}(w) = \|t - \Phi w\|_2^2 + \lambda\|w\|_2^2$, se establece la equivalencia exacta del parámetro de regularización:

$$\lambda = \frac{\sigma_\eta^2}{\sigma_w^2} = \frac{\text{Varianza del ruido observacional}}{\text{Varianza del prior sobre los pesos}}.$$

3. Deducción Analítica de la Solución Cerrada

Sustituyendo λ en la función objetivo a minimizar:

$$J(w) = \|t - \Phi w\|_2^2 + \lambda\|w\|_2^2 = (t - \Phi w)^\top (t - \Phi w) + \lambda w^\top w.$$

Expandiendo algebraicamente y agrupando términos:

$$\begin{aligned}
J(w) &= t^\top t - 2w^\top \Phi^\top t + w^\top \Phi^\top \Phi w + \lambda w^\top w \\
&= t^\top t - 2w^\top \Phi^\top t + w^\top (\Phi^\top \Phi + \lambda I_Q) w.
\end{aligned}$$

Calculando el gradiente respecto a w e igualando a cero:

$$\nabla_w J(w) = -2\Phi^\top t + 2(\Phi^\top \Phi + \lambda I_Q)w = \mathbf{0}$$
$$(\Phi^\top \Phi + \lambda I_Q)w = \Phi^\top t.$$

Dado que $\Phi^\top \Phi$ es semidefinida positiva y $\lambda > 0$, la matriz $(\Phi^\top \Phi + \lambda I_Q)$ es estrictamente invertible. Despejando el vector:

$$\hat{w}_{\text{MAP}} = \left(\Phi^\top \Phi + \lambda I_Q\right)^{-1} \Phi^\top t = \left(\Phi^\top \Phi + \frac{\sigma_\eta^2}{\sigma_w^2} I_Q\right)^{-1} \Phi^\top t.$$

4. Interpretación Física y Casos Límite

- **Prior no informativo ($\sigma_w^2 \to \infty$):** Ignorancia total a priori sobre los pesos. El parámetro se anula ($\lambda \to 0$), recuperando OLS y MLE:

$$\lim_{\sigma_w^2 \to \infty} \hat{w}_{\text{MAP}} = (\Phi^\top \Phi)^{-1} \Phi^\top t = \hat{w}_{\text{OLS}} \equiv \hat{w}_{\text{MLE}}.$$

- **Observaciones sin ruido ($\sigma_\eta^2 \to 0$):** Confianza plena en los datos observados. Se anula la regularización ($\lambda \to 0 \implies \hat{w}_{\text{MAP}} \to \hat{w}_{\text{OLS}}$).
- **Prior restrictivo ($\sigma_w^2 \to 0$):** Certeza absoluta de que los pesos valen cero. La penalización domina ($\lambda \to \infty$), encogiendo los coeficientes al origen: $\hat{w}_{\text{MAP}} \to \mathbf{0}$.

Resultado Final — Estimador MAP y Enlace Bayesiano:

$$\hat{w}_{\text{MAP}} = \left(\Phi^\top \Phi + \frac{\sigma_\eta^2}{\sigma_w^2} I_Q\right)^{-1} \Phi^\top t, \quad \text{con} \quad \lambda = \frac{\sigma_\eta^2}{\sigma_w^2}$$

La regularización cuadrática de Ridge no es una técnica heurística arbitraria: es la consecuencia analítica exacta de aplicar inferencia bayesiana bajo un prior gaussiano, donde la constante de penalización λ emerge naturalmente como la razón de incertidumbres entre el ruido observacional y el prior.

Punto 1.5: Implementación Numérica y Análisis Comparativo

Enunciado 1.5: Implementación y Análisis

1.5 Implementación y análisis. Implemente y compare los cuatro enfoques anteriores en Python usando $N = 300$, $P = 5$ y $Q = 20$, con $\Phi : \mathbb{R}^{N\times P} \to \mathbb{R}^{N\times Q}$. Para generar los datos:

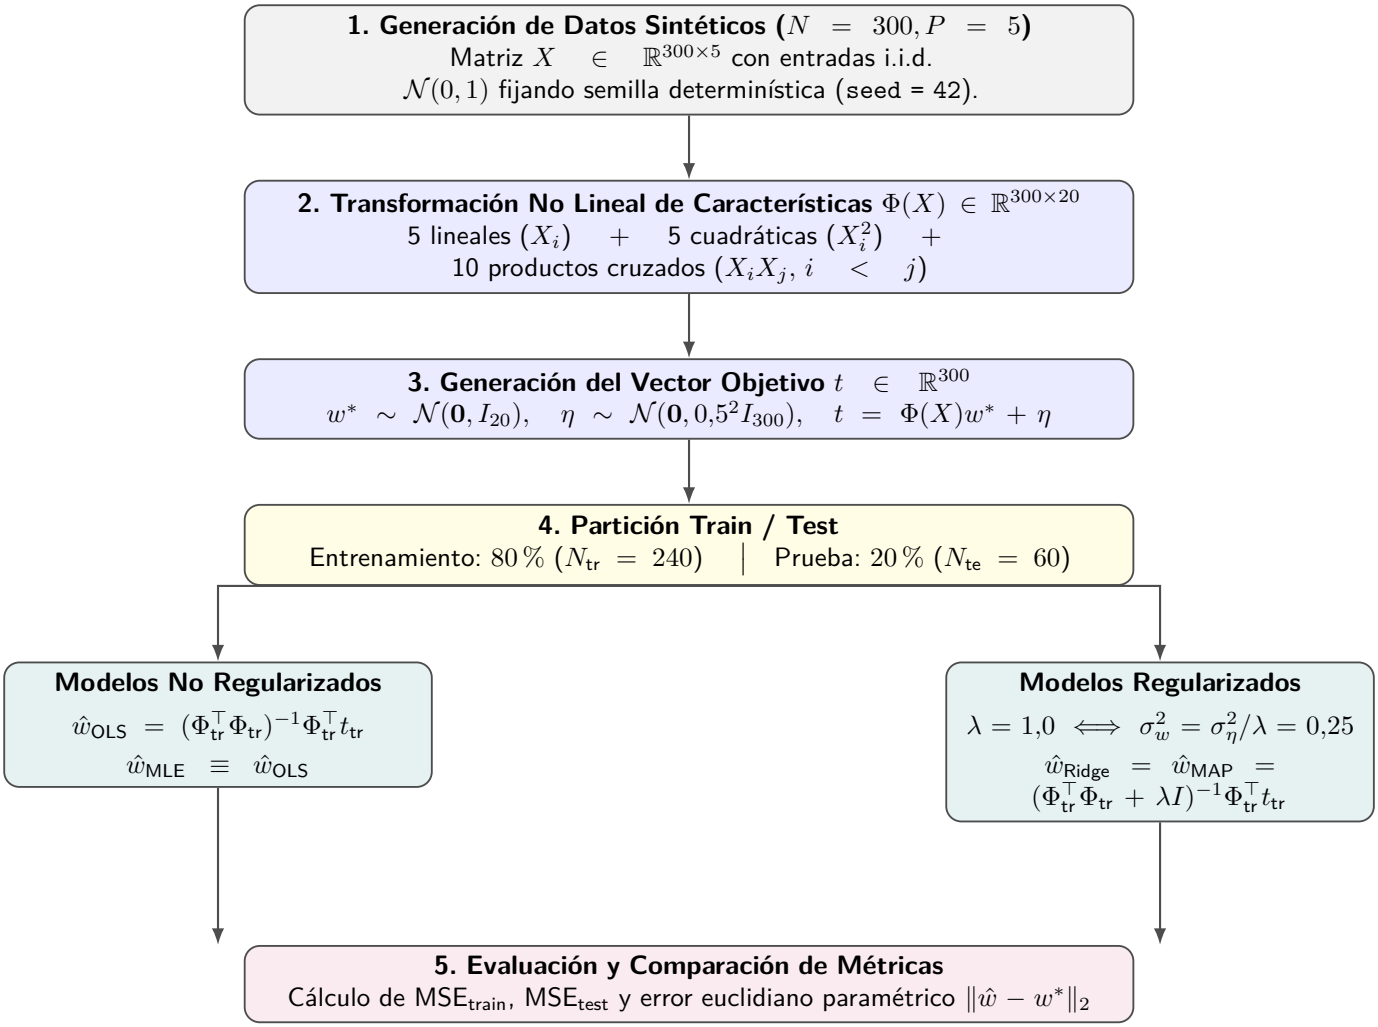
- Fije una semilla aleatoria y genere las filas de $X \in \mathbb{R}^{N\times P}$ de forma i.i.d. con entradas $\mathcal{N}(0,1)$.
- Construya una transformación reproducible $\Phi(X)$ de $Q = 20$ características: concatene las $P = 5$ columnas originales, sus cuadrados (5 columnas) y los $\binom{5}{2} = 10$ productos por pares de columnas distintas. Indique el orden utilizado.
- Genere $w^* \in \mathbb{R}^{20}$ con entradas i.i.d. $\mathcal{N}(0,1)$ y $\eta_n \sim \mathcal{N}(0,0{,}5^2)$ de forma independiente. Defina $t = \Phi(X)w^* + \eta$.
- Separe aleatoriamente los datos en entrenamiento (80 %) y prueba (20 %). Ajuste los cuatro estimadores usando únicamente entrenamiento; para los modelos regularizados use, por ejemplo, $\lambda = 1{,}0$ y el prior compatible $\sigma_w^2 = \sigma_\eta^2/\lambda$, según la convención empleada.
- Reporte el error cuadrático medio en entrenamiento y prueba, y $\|\hat{w} - w^*\|_2$. Compare las soluciones y explique las coincidencias esperadas entre mínimos cuadrados y máxima verosimilitud, y entre regularización cuadrática y MAP. Justifique cualquier discrepancia numérica.

Acceso al Cuaderno Interactivo en Google Colab

La implementación en Python, totalmente documentada y reproducible mediante semilla aleatoria, se encuentra disponible en:

https://colab.research.google.com/drive/1QV7x_AFNLaaka8IVSviLjn-xANdI9i4i?usp=sharing

Diagrama de Flujo del Proceso Computacional



1. Especificación del Orden de Características en $\Phi(X)$

Para garantizar reproducibilidad absoluta, las $Q = 20$ columnas de la matriz de diseño $\Phi(X)$ se ordenaron de manera determinística:

1. **Términos Lineales (5 columnas, índices 0 a 4):** X_0, X_1, X_2, X_3, X_4.
2. **Términos Cuadráticos (5 columnas, índices 5 a 9):** $X_0^2, X_1^2, X_2^2, X_3^2, X_4^2$.
3. **Términos de Interacción / Productos Cruzados (10 columnas, índices 10 a 19):** Pares lexicográficos (i, j) con $0 \le i < j \le 4$: (X_0X_1), (X_0X_2), (X_0X_3), (X_0X_4), (X_1X_2), (X_1X_3), (X_1X_4), (X_2X_3), (X_2X_4), (X_3X_4).

2. Resultados Numéricos y Métricas de Desempeño

Modelo Estimador	**MSE Train**	**MSE Test**	$\|\hat{w} - w^*\|_2$
Mínimos Cuadrados Ordinarios (OLS)	0.22152	0.26037	0.16309
Máxima Verosimilitud (MLE)	0.22152	0.26037	0.16309
Regularización Ridge ($\lambda = 1.0$)	0.22183	0.25789	0.15327
Máximo a Posteriori (MAP, $\sigma_w^2 = 0.25$)	0.22183	0.25789	0.15327

Cuadro 1: Métricas empíricas obtenidas para cada enfoque bajo la semilla fija: error cuadrático medio en entrenamiento ($N_{\text{tr}} = 240$), error de generalización en prueba ($N_{\text{te}} = 60$) y distancia euclidiana respecto al vector de parámetros generador real w^*.

3. Discusión Crítica de Resultados

1. **Coincidencia OLS vs. MLE:** Al asumir ruido gaussiano con varianza constante, maximizar la probabilidad da exactamente la misma fórmula que minimizar el error al cuadrado:

   $$\hat{w}_{\text{MLE}} = \hat{w}_{\text{OLS}} = (\Phi_{\text{tr}}^\top \Phi_{\text{tr}})^{-1} \Phi_{\text{tr}}^\top t_{\text{tr}}.$$

   En la práctica con Python, la diferencia entre ambos es $\|\hat{w}_{\text{OLS}} - \hat{w}_{\text{MLE}}\|_\infty = 0{,}0$, confirmando que son idénticos.

2. **Coincidencia Ridge vs. MAP:** Al usar un prior gaussiano centrado en cero, MAP penaliza los pesos grandes igual que Ridge. Si igualamos la penalización con las varianzas:

   $$\lambda = \frac{\sigma_\eta^2}{\sigma_w^2} = \frac{0{,}5^2}{0{,}25} = 1{,}0,$$

   ambos métodos resuelven exactamente la misma ecuación. En Python la diferencia entre sus pesos también es $\|\hat{w}_{\text{Ridge}} - \hat{w}_{\text{MAP}}\|_\infty = 0{,}0$.

3. **Efecto de la Regularización:**

   - **En Entrenamiento:** OLS y MLE tienen un error un poquito menor (0,22152 frente a 0,22183) porque intentan pegarse a los datos de entrenamiento sin ningún freno.
   - **En Prueba (Generalización):** Ridge y MAP ganan en los datos nuevos que no vieron antes (0,25789 frente a 0,26037). Al frenar el tamaño de los pesos, el ruido no arruina las predicciones.
   - **Recuperación del Valor Real (w^*):** Ridge y MAP quedaron más cerca de los verdaderos pesos originales (0,15327 de distancia frente a 0,16309 de OLS), demostrando que la regularización evita el sobreajuste.

Problema 2: Espacios RKHS, Embeddings de Media y Discrepancia entre Distribuciones

Premisa Oficial: Sea $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ un kernel simétrico definido positivo, y sea $\mathcal{H}_k$ el espacio de Hilbert con núcleo reproductor asociado (RKHS).

Punto 2.1: Definición Rigurosa del Embedding de Media

Enunciado Oficial: Defina rigurosamente el embedding de media asociado a una variable aleatoria X:

$$\mu_k = \mathbb{E}[k(X, \cdot)].$$

Sea X una variable aleatoria sobre el dominio $\mathcal{X}$ con distribución de probabilidad P_X, y sea $\mathcal{H}_k$ el espacio de Hilbert con kernel reproductor (RKHS) asociado a un kernel simétrico definido positivo $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$.

1. **Definición Poblacional y Mapeo de Características:**
   Buscamos representar la distribución de X en el espacio de Hilbert $\mathcal{H}_k$ mediante su valor esperado $\mathbb{E}[\phi(X)]$. Dado que el vector de características $\phi(x)$ puede tener dimensión infinita, utilizamos el mapeo canónico $\phi(x) = k(x, \cdot)$. El *embedding de media poblacional* se define formalmente como:

   $$\mu_k \triangleq \mathbb{E}_{X \sim P_X}[k(X, \cdot)] = \int_{\mathcal{X}} k(x, \cdot)\, dP_X(x) \in \mathcal{H}_k.$$

   El punto libre $(\cdot)$ indica el argumento donde la función espera ser evaluada; por ende, μ_k **no es un vector numérico ni un escalar, sino una función** perteneciente a $\mathcal{H}_k$.

2. **Condición de Existencia:**
   Para garantizar que μ_k esté bien definido y tenga norma finita en $\mathcal{H}_k$ ($\|\mu_k\|_{\mathcal{H}_k} < \infty$), se exige la condición de integrabilidad:

   $$\mathbb{E}_{X \sim P_X}\left[\sqrt{k(X, X)}\right] < \infty.$$

   Para kernels acotados (como el Gaussiano/RBF, donde $k(x, x) = 1$), esta condición se satisface trivialmente para cualquier distribución de datos ($\mathbb{E}[1] = 1 < \infty$).

3. **Estimador Empírico (Muestras i.i.d.):**
   Dado que la distribución teórica P_X es desconocida, en la práctica disponemos de una muestra observada de N datos independientes e idénticamente distribuidos (i.i.d.) $\{x_1, x_2, \ldots, x_N\} \sim P_X$. El embedding poblacional se aproxima mediante el promedio muestral:

   $$\hat{\mu}_k = \frac{1}{N} \sum_{n=1}^{N} k(x_n, \cdot) \in \mathcal{H}_k.$$

   Esta formulación permite representar empíricamente toda la muestra como una combinación lineal de kernels centrados en cada dato observado, sin necesidad de calcular explícitamente el espacio de características de dimensión infinita.

Punto 2.2: Pertenencia al Espacio RKHS e Interpretación Geométrica

Enunciado Oficial: Explique por qué $\mu_k \in \mathcal{H}_k$ e interprete geométricamente su significado como representante de la distribución de X en el espacio RKHS.

1. **Demostración de Pertenencia ($\mu_k \in \mathcal{H}_k$):**
   Un elemento pertenece al espacio de Hilbert $\mathcal{H}_k$ si su norma inducida es finita ($\|\mu_k\|_{\mathcal{H}_k} < \infty$). Calculamos su norma al cuadrado introduciendo dos variables aleatorias independientes con la misma distribución $X, X' \sim P_X$:

   $$\|\mu_k\|^2_{\mathcal{H}_k} = \langle \mu_k, \mu_k \rangle_{\mathcal{H}_k} = \left\langle \mathbb{E}[k(X, \cdot)],\, \mathbb{E}[k(X', \cdot)] \right\rangle_{\mathcal{H}_k} = \mathbb{E}_{X, X'}\left[\langle k(X, \cdot), k(X', \cdot) \rangle_{\mathcal{H}_k} \right].$$

Aplicando la propiedad del kernel ($\langle k(X,\cdot), k(X',\cdot)\rangle_{\mathcal{H}_k} = k(X,X')$), la norma se reduce a la similitud promedio entre pares de observaciones:

$$\|\mu_k\|^2_{\mathcal{H}_k} = \mathbb{E}_{X,X'}[k(X,X')].$$

Dado que el kernel es acotado (para el caso del kernel Gaussiano, $k(X,X') \leq 1$ para cualquier par de puntos):

$$\|\mu_k\|^2_{\mathcal{H}_k} \leq 1 < \infty \implies \mu_k \in \mathcal{H}_k.$$

Al ser su norma estrictamente finita, queda garantizado que μ_k es un elemento bien definido dentro de $\mathcal{H}_k$.

2. **Interpretación Geométrica en el RKHS:**

   - **Centro de masa (Baricentro funcional):** De forma análoga a como la media clásica $\mathbb{E}[X]$ representa el centroide de una nube de datos en $\mathbb{R}^P$, en el espacio RKHS el embedding μ_k actúa como el **centro de masa** de toda la distribución P_X proyectada en el espacio de funciones $\mathcal{H}_k$.
   - **Representante Único de la Distribución:** Para kernels característicos (como el Gaussiano), el mapeo $P \mapsto \mu_k$ es inyectivo:

     $$\mu_P = \mu_Q \iff P = Q.$$

     Esto significa que un único punto geométrico $\mu_k \in \mathcal{H}_k$ encapsula la distribución completa (media, varianza y momentos de orden superior) sin pérdida de información.

Punto 2.3: Derivación Paso a Paso de la Forma Matricial de MMD^2

Enunciado Oficial: Sean dos variables aleatorias independientes $X \sim P_X$ y $Y \sim P_Y$, definidas sobre un mismo dominio $\mathcal{X}$, con embeddings de media en el RKHS $\mathcal{H}_k$:

$$\mu_X = \mathbb{E}[k(X,\cdot)], \quad \mu_Y = \mathbb{E}[k(Y,\cdot)].$$

La distancia cuadrática entre dichos embeddings se define mediante:

$$\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k}.$$

Considere dos muestras independientes $\{x_i\}_{i=1}^n$ y $\{y_j\}_{j=1}^m$, extraídas de P_X y P_Y, respectivamente. Demuestre, a partir de la expresión anterior, que el estimador empírico sesgado se puede escribir en la siguiente forma matricial:

$$\widehat{\mathrm{MMD}}^2_b = \frac{1}{n^2}\mathbf{1}_n^\top \mathbf{K}_{XX}\mathbf{1}_n + \frac{1}{m^2}\mathbf{1}_m^\top \mathbf{K}_{YY}\mathbf{1}_m - \frac{2}{nm}\mathbf{1}_n^\top \mathbf{K}_{XY}\mathbf{1}_m.$$

Aquí $\mathbf{K}_{XX} \in \mathbb{R}^{n\times n}$, $\mathbf{K}_{YY} \in \mathbb{R}^{m\times m}$ y $\mathbf{K}_{XY} \in \mathbb{R}^{n\times m}$ son las matrices de Gram correspondientes. En la demostración desarrolle los productos internos, utilice la propiedad reproductora para llegar a las expresiones con el kernel, establezca la versión empírica y justifique las dimensiones de cada término. Distinga el estimador sesgado de la formulación poblacional.

Punto 2.3: Discrepancia Máxima de Medias (MMD) y Estimador Matricial Sesgado

Enunciado Oficial: Demuestre a partir de la distancia entre embeddings en $\mathcal{H}_k$ que el estimador empírico sesgado de MMD^2 se escribe en forma matricial como:

$$\widehat{\text{MMD}}_b^2 = \frac{1}{n^2}\mathbf{1}_n^\top \mathbf{K}_{XX}\mathbf{1}_n + \frac{1}{m^2}\mathbf{1}_m^\top \mathbf{K}_{YY}\mathbf{1}_m - \frac{2}{nm}\mathbf{1}_n^\top \mathbf{K}_{XY}\mathbf{1}_m.$$

Desarrolle los productos internos, use la propiedad reproductora, justifique las dimensiones y distinga la versión sesgada de la poblacional.

a) **Expansión de la Norma Cuadrada (Desarrollo del Binomio):**
Por definición, la discrepancia cuadrática entre dos embeddings en el espacio de Hilbert $\mathcal{H}_k$ se expande mediante la linealidad del producto interno:

$$\begin{aligned}\|\mu_X - \mu_Y\|_{\mathcal{H}_k}^2 &= \langle \mu_X - \mu_Y,\, \mu_X - \mu_Y\rangle_{\mathcal{H}_k} \\ &= \underbrace{\langle \mu_X, \mu_X\rangle_{\mathcal{H}_k}}_{(I)} + \underbrace{\langle \mu_Y, \mu_Y\rangle_{\mathcal{H}_k}}_{(II)} - 2\underbrace{\langle \mu_X, \mu_Y\rangle_{\mathcal{H}_k}}_{(III)}.\end{aligned}$$

b) **Embeddings Empíricos y Notación de Índices:**
Dadas las muestras observadas independientes $\{x_i\}_{i=1}^n \sim P_X$ y $\{y_j\}_{j=1}^m \sim P_Y$, los estimadores empíricos de media son:

$$\hat{\mu}_X = \frac{1}{n}\sum_{i=1}^n k(x_i,\cdot) \in \mathcal{H}_k, \qquad \hat{\mu}_Y = \frac{1}{m}\sum_{j=1}^m k(y_j,\cdot) \in \mathcal{H}_k.$$

Para calcular los productos internos sin ambigüedad de índices, definimos los rangos de iteración:

$$i, i' \in \{1, 2, \ldots, n\} \quad \text{(muestras de } X\text{)}, \qquad j, j' \in \{1, 2, \ldots, m\} \quad \text{(muestras de } Y\text{)}.$$

c) **Desarrollo Término a Término mediante la Propiedad Reproductora:**
Evaluamos cada uno de los tres términos sustituyendo los embeddings empíricos:

- **Término** (I) **— Auto-similitud de** X**:**

$$\langle \hat{\mu}_X, \hat{\mu}_X\rangle_{\mathcal{H}_k} = \left\langle \frac{1}{n}\sum_{i=1}^n k(x_i,\cdot),\, \frac{1}{n}\sum_{i'=1}^n k(x_{i'},\cdot)\right\rangle_{\mathcal{H}_k} = \frac{1}{n^2}\sum_{i=1}^n\sum_{i'=1}^n \langle k(x_i,\cdot), k(x_{i'},\cdot)\rangle_{\mathcal{H}_k}.$$

  Por la propiedad del kernel ($\langle k(x_i,\cdot), k(x_{i'},\cdot)\rangle_{\mathcal{H}_k} = k(x_i, x_{i'})$), la suma doble evalúa la matriz de Gram $\mathbf{K}_{XX} \in \mathbb{R}^{n\times n}$, donde $[\mathbf{K}_{XX}]_{i,i'} = k(x_i, x_{i'})$. Dado que pre y post-multiplicar por el vector de unos $\mathbf{1}_n = [1, \ldots, 1]^\top \in \mathbb{R}^{n\times 1}$ suma todas las componentes de la matriz:

$$\langle \hat{\mu}_X, \hat{\mu}_X\rangle_{\mathcal{H}_k} = \frac{1}{n^2}\sum_{i=1}^n\sum_{i'=1}^n k(x_i, x_{i'}) = \frac{1}{n^2}\mathbf{1}_n^\top \mathbf{K}_{XX}\mathbf{1}_n.$$

- **Término** (II) **— Auto-similitud de** Y**:**
  De forma idéntica, con índices $j, j' \in \{1, \ldots, m\}$ y la matriz $\mathbf{K}_{YY} \in \mathbb{R}^{m\times m}$ ($[\mathbf{K}_{YY}]_{j,j'} = k(y_j, y_{j'})$):

$$\langle \hat{\mu}_Y, \hat{\mu}_Y\rangle_{\mathcal{H}_k} = \frac{1}{m^2}\sum_{j=1}^m\sum_{j'=1}^m k(y_j, y_{j'}) = \frac{1}{m^2}\mathbf{1}_m^\top \mathbf{K}_{YY}\mathbf{1}_m.$$

- **Término (III) — Similitud Cruzada entre X e Y:**
  Emparejando las observaciones con índices $i \in \{1, \ldots, n\}$ y $j \in \{1, \ldots, m\}$:

$$\langle \hat{\mu}_X, \hat{\mu}_Y \rangle_{\mathcal{H}_k} = \left\langle \frac{1}{n} \sum_{i=1}^{n} k(x_i, \cdot),\ \frac{1}{m} \sum_{j=1}^{m} k(y_j, \cdot) \right\rangle_{\mathcal{H}_k} = \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} k(x_i, y_j).$$

  Definiendo la matriz cruzada $\mathbf{K}_{XY} \in \mathbb{R}^{n \times m}$ ($[\mathbf{K}_{XY}]_{i,j} = k(x_i, y_j)$):

$$\langle \hat{\mu}_X, \hat{\mu}_Y \rangle_{\mathcal{H}_k} = \frac{1}{nm} \mathbf{1}_n^\top \mathbf{K}_{XY} \mathbf{1}_m.$$

d) **Expresión Matricial Final y Justificación Dimensional:**
Sustituyendo los tres términos en la norma desarrollada:

$$\widehat{\mathrm{MMD}}_b^2 = \frac{1}{n^2} \mathbf{1}_n^\top \mathbf{K}_{XX} \mathbf{1}_n + \frac{1}{m^2} \mathbf{1}_m^\top \mathbf{K}_{YY} \mathbf{1}_m - \frac{2}{nm} \mathbf{1}_n^\top \mathbf{K}_{XY} \mathbf{1}_m \quad \blacksquare$$

Análisis dimensional:

- $\mathbf{1}_n^\top \mathbf{K}_{XX} \mathbf{1}_n \in \mathbb{R}^{(1\times n)\times(n\times n)\times(n\times 1)} \implies 1 \times 1$ (escalar real).
- $\mathbf{1}_m^\top \mathbf{K}_{YY} \mathbf{1}_m \in \mathbb{R}^{(1\times m)\times(m\times m)\times(m\times 1)} \implies 1 \times 1$ (escalar real).
- $\mathbf{1}_n^\top \mathbf{K}_{XY} \mathbf{1}_m \in \mathbb{R}^{(1\times n)\times(n\times m)\times(m\times 1)} \implies 1 \times 1$ (escalar real).

Por lo tanto, la resta combinada produce un escalar estrictamente consistente.

e) **Distinción entre Formulación Poblacional y Estimador Sesgado:**

- **Formulación Poblacional (Insesgada):** Desacopla pares independientes de variables:

$$\mathrm{MMD}^2(P_X, P_Y) = \mathbb{E}_{X,X'}[k(X, X')] + \mathbb{E}_{Y,Y'}[k(Y, Y')] - 2\mathbb{E}_{X,Y}[k(X, Y)].$$

- **¿Por qué es sesgado el estimador $\widehat{\mathrm{MMD}}_b^2$?**
  En las sumas de $\mathbf{K}_{XX}$ y $\mathbf{K}_{YY}$ se incluyen los términos de la **diagonal principal** ($i = i'$ y $j = j'$), donde cada dato se compara consigo mismo ($k(x_i, x_i) = 1$). Esto introduce un sesgo positivo artificial de orden $\mathcal{O}(1/n + 1/m)$. Por lo tanto, para muestras finitas:

$$\mathbb{E}[\widehat{\mathrm{MMD}}_b^2] > \mathrm{MMD}^2(P_X, P_Y).$$

  Este sesgo se desvanece asintóticamente cuando $n, m \to \infty$.

2.4 Implementación Numérica con MNIST y Fashion-MNIST

1. Formulación Matricial y Dimensiones:
Para dos conjuntos de $n = m = 500$ imágenes normalizadas en $[0, 1]^{784}$ (28×28 píxeles), el estimador empírico sesgado de MMD^2 se evalúa matricialmente como:

$$\widehat{\mathrm{MMD}}_b^2 = \frac{1}{n^2} \mathbf{1}_n^\top \mathbf{K}_{XX} \mathbf{1}_n + \frac{1}{m^2} \mathbf{1}_m^\top \mathbf{K}_{YY} \mathbf{1}_m - \frac{2}{nm} \mathbf{1}_n^\top \mathbf{K}_{XY} \mathbf{1}_m$$

Dimensiones de los operadores:

- Matrices de Gram: $\mathbf{K}_{XX} \in \mathbb{R}^{500\times500}$, $\mathbf{K}_{YY} \in \mathbb{R}^{500\times500}$ y $\mathbf{K}_{XY} \in \mathbb{R}^{500\times500}$, calculadas mediante el kernel gaussiano $k(u,v) = \exp\left(-\frac{\|u-v\|_2^2}{2\sigma^2}\right)$.
- Vectores unitarios de suma: $\mathbf{1}_n \in \mathbb{R}^{500\times1}$ y $\mathbf{1}_m \in \mathbb{R}^{500\times1}$.

El ancho de banda se fijó mediante la **heurística de la mediana** sobre las distancias euclidianas de todos los pares de la muestra combinada (1 000 imágenes):

$$\sigma = \text{mediana}\Big(\{\|z_i - z_j\|_2 : 1 \le i < j \le 1000\}\Big) \approx 11.0550$$

2. Resultados Numéricos Obtenidos:

Comparación Experimental	**Término** XX	**Término** YY	**Término** XY $(2\times)$	$\widehat{\text{MMD}}_b^2$
MNIST_1 vs. Fashion_1	0.659563	0.593651	1.120527	**0.132687**
MNIST_1 vs. MNIST_2 (Control Nulo)	0.659563	0.661352	1.319579	**0.001335**
Fashion_1 vs. Fashion_2 (Control Nulo)	0.593651	0.584801	1.176473	**0.001979**

3. Discusión Crítica de Resultados:

- **Discriminación Distribucional:** La discrepancia inter-dataset ($\widehat{\text{MMD}}_b^2 \approx 0.1327$) es **dos órdenes de magnitud superior** a los controles nulos (≈ 0.0013 y 0.0019). Esto se debe a que los trazos delgados con fondo nulo en MNIST y las siluetas densas y con textura de Fashion-MNIST generan distancias euclidianas grandes, reduciendo la similitud cruzada ($2 \times XY = 1.1205$) respecto a la auto-similitud ($XX + YY = 1.2532$). Sus representaciones medias en $\mathcal{H}_k$ están marcadamente distanciadas.
- **Influencia del Ancho de Banda (σ):** Si $\sigma \to 0$, las evaluaciones gaussianas colapsan a deltas de Dirac ($\mathbf{K} \to \mathbf{I}$), de modo que $\widehat{\text{MMD}}_b^2 \to \frac{2}{500} = 0.004$ para cualquier par, anulando la discriminación. Si $\sigma \to \infty$, la similitud entre cualquier imagen tiende a 1 ($\mathbf{K} \to \mathbf{1}\mathbf{1}^\top$), con lo cual $\widehat{\text{MMD}}_b^2 \to 0$ independientemente de los datos. La heurística de la mediana ubica a σ en el régimen de máxima tasa de cambio del kernel, maximizando la potencia del test.
- **Variabilidad Muestral y Sesgo Empírico:** Teóricamente, bajo la misma distribución se tiene $\text{MMD}^2(P,P) = 0$. Los valores residuales no nulos (0.001335 y 0.001979) reflejan el **sesgo empírico intrínseco** $\mathcal{O}(1/n)$ demostrado en 2.3 provocado por los términos de auto-similitud diagonal ($k(x_i,x_i) = 1$), sumado a la fluctuación estocástica finita de tomar subconjuntos de 500 muestras.
- **Límites sin Contraste de Hipótesis Formal:** Dado que $\widehat{\text{MMD}}_b^2 \ge 0$ por ser una distancia cuadrática en un espacio de Hilbert, un valor positivo jamás prueba por sí solo que las distribuciones difieran. Para una conclusión rigurosa se debe realizar un **test de permutación** bajo $H_0 : P_X = P_Y$ mezclando aleatoriamente las muestras para construir la distribución nula empírica y contrastar formalmente con p-valor < 0.05.

Problema 3: Coeficiente de Pearson y Métodos Kernel

Punto 3.1

Enunciado 3.1: Coeficiente de Pearson en el Espacio Original

3.1 Coeficiente de Pearson en el espacio original. Sean X y Y dos variables aleatorias escalares, con varianzas positivas, y sean $\mathbf{x}, \mathbf{y} \in \mathbb{R}^{N\times 1}$ los vectores de N observaciones emparejadas. A partir de la definición

$$\rho_{XY} = \frac{\mathbb{E}[(X-\mu_X)(Y-\mu_Y)]}{\sqrt{\mathbb{E}[(X-\mu_X)^2]\,\mathbb{E}[(Y-\mu_Y)^2]}},$$

demuestre que el coeficiente de Pearson muestral puede expresarse matricialmente como

$$\hat{\rho}_{XY} = \frac{\mathbf{x}^\top H \mathbf{y}}{\sqrt{(\mathbf{x}^\top H \mathbf{x})(\mathbf{y}^\top H \mathbf{y})}}, \qquad H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top.$$

Justifique el paso de las medias y sumatorias a la forma matricial, el centrado y las dimensiones.

Transición de la Definición Poblacional al Estimador Muestral

Dada una muestra de N observaciones emparejadas $\{(x_n, y_n)\}_{n=1}^N$, las medias poblacionales μ_X y μ_Y se aproximan mediante las medias muestrales:

$$\bar{x} = \frac{1}{N}\sum_{n=1}^N x_n, \qquad \bar{y} = \frac{1}{N}\sum_{n=1}^N y_n.$$

Por el principio de estimación empírica (*plug-in estimator*), el operador esperanza matemática $\mathbb{E}[g(X,Y)]$ se reemplaza por el promedio aritmético sobre la muestra $\frac{1}{N}\sum_{n=1}^N g(x_n, y_n)$. Aplicando esto término a término:

a) **Numerador (Covarianza muestral):**

$$\mathbb{E}[(X-\mu_X)(Y-\mu_Y)] \approx \frac{1}{N}\sum_{n=1}^N (x_n-\bar{x})(y_n-\bar{y}).$$

b) **Denominador (Varianzas muestrales):**

$$\begin{aligned}\sqrt{\mathbb{E}[(X-\mu_X)^2]\,\mathbb{E}[(Y-\mu_Y)^2]} &\approx \sqrt{\left[\frac{1}{N}\sum_{n=1}^N (x_n-\bar{x})^2\right]\left[\frac{1}{N}\sum_{n=1}^N (y_n-\bar{y})^2\right]} \\ &= \sqrt{\frac{1}{N^2}\left(\sum_{n=1}^N (x_n-\bar{x})^2\right)\left(\sum_{n=1}^N (y_n-\bar{y})^2\right)} \\ &= \frac{1}{N}\sqrt{\sum_{n=1}^N (x_n-\bar{x})^2 \sum_{n=1}^N (y_n-\bar{y})^2}.\end{aligned}$$

Sustituyendo ambos términos en la definición del estimador muestral $\hat{\rho}_{XY}$:

$$\hat{\rho}_{XY} = \frac{\frac{1}{N}\sum_{n=1}^N (x_n-\bar{x})(y_n-\bar{y})}{\frac{1}{N}\sqrt{\sum_{n=1}^N (x_n-\bar{x})^2 \sum_{n=1}^N (y_n-\bar{y})^2}}.$$

Cancelando el factor común $\frac{1}{N}$ entre numerador y denominador, obtenemos:

$$\hat{\rho}_{XY} = \frac{\sum_{n=1}^{N}(x_n - \bar{x})(y_n - \bar{y})}{\sqrt{\sum_{n=1}^{N}(x_n - \bar{x})^2 \sum_{n=1}^{N}(y_n - \bar{y})^2}}.$$

Vectorización del Centrado y Definición de la Matriz H

Definimos los vectores de observaciones y el vector de unos en $\mathbb{R}^{N\times 1}$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_N \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}, \quad \mathbf{1}_N = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}.$$

La suma de las componentes de $\mathbf{x}$ corresponde al producto interno $\sum_{n=1}^{N} x_n = \mathbf{1}_N^\top \mathbf{x}$. Por lo tanto, la media escalar se expresa matricialmente como:

$$\bar{x} = \frac{1}{N}\mathbf{1}_N^\top \mathbf{x}.$$

Definimos el vector de datos centrado $\mathbf{x}_c \in \mathbb{R}^{N\times 1}$:

$$\mathbf{x}_c = \begin{bmatrix} x_1 - \bar{x} \\ \vdots \\ x_N - \bar{x} \end{bmatrix} = \mathbf{x} - \bar{x}\mathbf{1}_N = \mathbf{x} - \mathbf{1}_N\bar{x}.$$

Sustituyendo la expresión matricial de la media $\bar{x}$:

$$\mathbf{x}_c = \mathbf{x} - \mathbf{1}_N\left(\frac{1}{N}\mathbf{1}_N^\top \mathbf{x}\right) = I_N\mathbf{x} - \left(\frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)\mathbf{x}.$$

Factorizando el vector $\mathbf{x}$ por la derecha:

$$\mathbf{x}_c = \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)\mathbf{x} = H\mathbf{x},$$

donde se define la **matriz de centrado** $H \in \mathbb{R}^{N\times N}$ como:

$$H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top.$$

De manera completamente análoga para $\mathbf{y}$:

$$\mathbf{y}_c = H\mathbf{y}.$$

Propiedades Algebraicas de la Matriz de Centrado H

Para compactar los productos vectoriales demostramos dos propiedades fundamentales de H:

a) **Simetría ($H^\top = H$):**

$$H^\top = \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)^\top = I_N^\top - \frac{1}{N}(\mathbf{1}_N\mathbf{1}_N^\top)^\top = I_N - \frac{1}{N}(\mathbf{1}_N^\top)^\top\mathbf{1}_N^\top = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = H.$$

b) **Idempotencia ($H^2 = H$):**

$$\begin{aligned} H^2 = HH &= \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)\left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right) \\ &= I_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\top + \frac{1}{N^2}\mathbf{1}_N(\mathbf{1}_N^\top\mathbf{1}_N)\mathbf{1}_N^\top. \end{aligned}$$

Dado que $\mathbf{1}_N^\top\mathbf{1}_N = \sum_{n=1}^{N} 1 = N$:

$$H^2 = I_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\top + \frac{1}{N^2}\mathbf{1}_N(N)\mathbf{1}_N^\top = I_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\top + \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = H.$$

Combinando simetría e idempotencia se deduce que:

$$H^\top H = HH = H^2 = H.$$

Formulación Matricial de las Formas Bilineales y Cuadráticas

Expresamos los términos de la fórmula muestral en función de $\mathbf{x}_c = H\mathbf{x}$ e $\mathbf{y}_c = H\mathbf{y}$:

- **Numerador:**

$$\sum_{n=1}^{N}(x_n - \bar{x})(y_n - \bar{y}) = \mathbf{x}_c^\top\mathbf{y}_c = (H\mathbf{x})^\top(H\mathbf{y}) = \mathbf{x}^\top H^\top H\mathbf{y} = \mathbf{x}^\top H\mathbf{y}.$$

- **Denominador:**

$$\sum_{n=1}^{N}(x_n - \bar{x})^2 = \mathbf{x}_c^\top\mathbf{x}_c = (H\mathbf{x})^\top(H\mathbf{x}) = \mathbf{x}^\top H^\top H\mathbf{x} = \mathbf{x}^\top H\mathbf{x},$$

$$\sum_{n=1}^{N}(y_n - \bar{y})^2 = \mathbf{y}_c^\top\mathbf{y}_c = (H\mathbf{y})^\top(H\mathbf{y}) = \mathbf{y}^\top H^\top H\mathbf{y} = \mathbf{y}^\top H\mathbf{y}.$$

Justificación Dimensional

Verificamos las dimensiones algebraicas de cada término involucrado:

- Vectores de observaciones: $\mathbf{x}, \mathbf{y} \in \mathbb{R}^{N\times 1} \implies \mathbf{x}^\top, \mathbf{y}^\top \in \mathbb{R}^{1\times N}$.
- Matriz de centrado: $H \in \mathbb{R}^{N\times N}$, resultado de restar a $I_N \in \mathbb{R}^{N\times N}$ el producto externo $\frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top \in \mathbb{R}^{N\times N}$.
- Numerador: $\mathbf{x}^\top H\mathbf{y} \in \mathbb{R}^{(1\times N)\times(N\times N)\times(N\times 1)} = \mathbb{R}^{1\times 1}$ (escalar real).
- Formas cuadráticas del denominador: $\mathbf{x}^\top H\mathbf{x} = \|\mathbf{x}_c\|_2^2 \in \mathbb{R}^{1\times 1}$ e $\mathbf{y}^\top H\mathbf{y} = \|\mathbf{y}_c\|_2^2 \in \mathbb{R}^{1\times 1}$. Dado el supuesto de varianzas positivas (las observaciones no son constantes), $\mathbf{x}_c \neq \mathbf{0}$ e $\mathbf{y}_c \neq \mathbf{0}$, por lo que $\mathbf{x}^\top H\mathbf{x} > 0$ e $\mathbf{y}^\top H\mathbf{y} > 0$. La raíz cuadrada y el cociente están bien definidos.

Por lo tanto, $\hat{\rho}_{XY} \in [-1, 1]$ es un escalar adimensional puro.

Resultado Final: Coeficiente de Pearson Matricial

$$\hat{\rho}_{XY} = \frac{\mathbf{x}^\top H\mathbf{y}}{\sqrt{(\mathbf{x}^\top H\mathbf{x})(\mathbf{y}^\top H\mathbf{y})}}, \qquad \text{con} \quad H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top$$

El coeficiente muestral equivale al coseno del ángulo entre los vectores centrados $\mathbf{x}_c = H\mathbf{x}$ e $\mathbf{y}_c = H\mathbf{y}$ en el espacio euclidiano $\mathbb{R}^N$: $\hat{\rho}_{XY} = \frac{\langle \mathbf{x}_c, \mathbf{y}_c\rangle}{\|\mathbf{x}_c\|_2\|\mathbf{y}_c\|_2}$.

Punto 3.2

Enunciado 3.2: Correlación Matricial en RKHS

3.2 Correlación matricial en RKHS. Sean dos variables aleatorias vectoriales $X \in \mathbb{R}^P$ y $Y \in \mathbb{R}^Q$, con N observaciones emparejadas, y sean k_X y k_Y sus respectivos kernels con matrices de Gram $K_X, K_Y \in \mathbb{R}^{N\times N}$. Partiendo del producto interno normalizado entre las matrices de Gram centradas, demuestre que el índice de alineamiento centrado en RKHS se expresa como

$$\rho_{\text{RKHS}}(K_X, K_Y) = \frac{\operatorname{tr}(K_X H K_Y H)}{\sqrt{\operatorname{tr}(K_X H K_X H)\operatorname{tr}(K_Y H K_Y H)}}.$$

Utilice $K_{X,c} = HK_XH$ y $K_{Y,c} = HK_YH$ para desarrollar la demostración desde productos internos y sumatorias hasta trazas; justifique sus dimensiones. Finalmente, para kernels lineales y $P = Q = 1$, demuestre que $\rho_{\text{RKHS}} = \hat{\rho}^2_{XY}$ y explique la pérdida del signo.
Nota: el índice de 3.2 es alineamiento centrado de kernels, no el coeficiente de Pearson clásico; suponga denominadores distintos de cero.

Espacio Matricial y Producto Interno de Frobenius

En el espacio vectorial de matrices cuadradas $\mathbb{R}^{N\times N}$, el producto interno canónico que compara dos matrices A y B término a término se define mediante la sumatoria doble:

$$\langle A, B\rangle_F = \sum_{i=1}^{N}\sum_{j=1}^{N} A_{ij}B_{ij}.$$

Para relacionar esta sumatoria con el operador traza $\operatorname{tr}(\cdot)$, consideremos el producto matricial $C = A^\top B \in \mathbb{R}^{N\times N}$. La regla estándar del producto de matrices establece que la entrada en la fila i y columna j es:

$$[A^\top B]_{ij} = \sum_{k=1}^{N}[A^\top]_{ik}B_{kj} = \sum_{k=1}^{N} A_{ki}B_{kj}.$$

Evaluando los elementos de la diagonal principal ($j = i$):

$$[A^\top B]_{ii} = \sum_{k=1}^{N} A_{ki}B_{ki}.$$

Sumando todos los elementos de la diagonal para calcular la traza:

$$\operatorname{tr}(A^\top B) = \sum_{i=1}^{N}[A^\top B]_{ii} = \sum_{i=1}^{N}\sum_{k=1}^{N} A_{ki}B_{ki} = \sum_{i=1}^{N}\sum_{j=1}^{N} A_{ji}B_{ji} \equiv \sum_{i=1}^{N}\sum_{j=1}^{N} A_{ij}B_{ij}.$$

Queda demostrado que:

$$\langle A, B\rangle_F = \operatorname{tr}(A^\top B).$$

La norma matricial inducida de Frobenius es:

$$\|A\|_F = \sqrt{\langle A, A\rangle_F} = \sqrt{\operatorname{tr}(A^\top A)}.$$

Definiendo la correlación normalizada (alineamiento) como el coseno del ángulo entre dos matrices centradas $K_{X,c}$ y $K_{Y,c}$ bajo este producto interno:

$$\rho_{\text{RKHS}}(K_X, K_Y) = \frac{\langle K_{X,c}, K_{Y,c}\rangle_F}{\|K_{X,c}\|_F\|K_{Y,c}\|_F} = \frac{\operatorname{tr}(K_{X,c}^\top K_{Y,c})}{\sqrt{\operatorname{tr}(K_{X,c}^\top K_{X,c})\operatorname{tr}(K_{Y,c}^\top K_{Y,c})}}.$$

Simetría y Deducción de la Formulación con Trazas

Las matrices de Gram asociadas a kernels simétricos satisfacen $K_X^\top = K_X$ y $K_Y^\top = K_Y$, y la matriz de centrado satisface $H^\top = H$. Por lo tanto, las matrices centradas $K_{X,c} = HK_XH$ y $K_{Y,c} = HK_YH$ son simétricas:

$$K_{X,c}^\top = (HK_XH)^\top = H^\top K_X^\top H^\top = HK_XH = K_{X,c}, \qquad K_{Y,c}^\top = K_{Y,c}.$$

Sustituyendo esta propiedad en el coseno:

$$\rho_{\text{RKHS}}(K_X, K_Y) = \frac{\operatorname{tr}(K_{X,c}K_{Y,c})}{\sqrt{\operatorname{tr}(K_{X,c}^2)\operatorname{tr}(K_{Y,c}^2)}}.$$

Desarrollamos analíticamente cada término:

- **Numerador:**

$$\begin{aligned}\operatorname{tr}(K_{X,c}K_{Y,c}) &= \operatorname{tr}\left((HK_XH)(HK_YH)\right)\\ &= \operatorname{tr}(HK_XH^2K_YH).\end{aligned}$$

  Por idempotencia de la matriz de centrado ($H^2 = H$):

$$\operatorname{tr}(K_{X,c}K_{Y,c}) = \operatorname{tr}(HK_XHK_YH).$$

  Por la propiedad cíclica del operador traza ($\operatorname{tr}(AB) = \operatorname{tr}(BA)$), desplazamos la primera matriz H al extremo derecho del producto:

$$\operatorname{tr}(H[K_XHK_YH]) = \operatorname{tr}([K_XHK_YH]H) = \operatorname{tr}(K_XHK_YH^2) = \operatorname{tr}(K_XHK_YH).$$

- **Denominador:** Aplicando la misma secuencia de idempotencia y propiedad cíclica para K_X:

  $\operatorname{tr}(K_{X,c}^2) = \operatorname{tr}\left((HK_XH)(HK_XH)\right) = \operatorname{tr}(HK_XH^2K_XH) = \operatorname{tr}(HK_XHK_XH) = \operatorname{tr}(K_XHK_XH).$

  De manera idéntica para K_Y:

$$\operatorname{tr}(K_{Y,c}^2) = \operatorname{tr}(K_YHK_YH).$$

Sustituyendo numerador y denominador se obtiene la expresión general requerida:

$$\boxed{\rho_{\text{RKHS}}(K_X, K_Y) = \frac{\operatorname{tr}(K_XHK_YH)}{\sqrt{\operatorname{tr}(K_XHK_XH)\operatorname{tr}(K_YHK_YH)}}.} \quad \blacksquare$$

Justificación Dimensional

Verificamos las dimensiones algebraicas:

- Matrices involucradas: $K_X, K_Y, H \in \mathbb{R}^{N\times N}$.
- Producto interno matricial: $K_XHK_YH \in \mathbb{R}^{N\times N}$.
- Operador traza: la aplicación $\operatorname{tr} : \mathbb{R}^{N\times N} \to \mathbb{R}$ suma los N elementos de la diagonal principal, generando escalares reales $\operatorname{tr}(K_XHK_YH) \in \mathbb{R}^{1\times 1}$.
- No negatividad del denominador: bajo el supuesto de denominadores distintos de cero, $\|K_{X,c}\|_F^2 = \operatorname{tr}(K_XHK_XH) > 0$ y $\|K_{Y,c}\|_F^2 = \operatorname{tr}(K_YHK_YH) > 0$.

Por la desigualdad de Cauchy-Schwarz en $\mathbb{R}^{N\times N}$ con producto interno de Frobenius, $\rho_{\text{RKHS}} \in [0, 1]$ es un escalar adimensional normalizado.

Caso Particular: Kernels Lineales con $P = Q = 1$

Consideremos variables escalares $x, y \in \mathbb{R}^{N\times 1}$ y el kernel lineal $k(u, v) = uv$:

$$K_X = \mathbf{x}\mathbf{x}^\top \in \mathbb{R}^{N\times N}, \qquad K_Y = \mathbf{y}\mathbf{y}^\top \in \mathbb{R}^{N\times N}.$$

Las matrices de Gram centradas toman la forma de productos externos de los vectores centrados $\mathbf{x}_c = H\mathbf{x}$ e $\mathbf{y}_c = H\mathbf{y}$:

$$K_{X,c} = H(\mathbf{x}\mathbf{x}^\top)H = (H\mathbf{x})(H\mathbf{x})^\top = \mathbf{x}_c\mathbf{x}_c^\top,$$
$$K_{Y,c} = H(\mathbf{y}\mathbf{y}^\top)H = (H\mathbf{y})(H\mathbf{y})^\top = \mathbf{y}_c\mathbf{y}_c^\top.$$

Evaluamos los términos de la traza:

- **Numerador:**
$$\operatorname{tr}(K_{X,c}K_{Y,c}) = \operatorname{tr}\left((\mathbf{x}_c\mathbf{x}_c^\top)(\mathbf{y}_c\mathbf{y}_c^\top)\right) = \operatorname{tr}\left(\mathbf{x}_c(\mathbf{x}_c^\top\mathbf{y}_c)\mathbf{y}_c^\top\right).$$
Como el producto punto $\mathbf{x}_c^\top\mathbf{y}_c \in \mathbb{R}$ es un escalar, se factoriza fuera de la traza:
$$\operatorname{tr}(K_{X,c}K_{Y,c}) = (\mathbf{x}_c^\top\mathbf{y}_c)\operatorname{tr}(\mathbf{x}_c\mathbf{y}_c^\top).$$
Por propiedad cíclica de la traza, $\operatorname{tr}(\mathbf{x}_c\mathbf{y}_c^\top) = \mathbf{y}_c^\top\mathbf{x}_c = \mathbf{x}_c^\top\mathbf{y}_c$. Por lo tanto:
$$\operatorname{tr}(K_XHK_YH) = (\mathbf{x}_c^\top\mathbf{y}_c)^2 = (\mathbf{x}^\top H\mathbf{y})^2.$$

- **Denominador:** Evaluando análogamente para $\mathbf{x}_c$:
$$\operatorname{tr}(K_XHK_XH) = \operatorname{tr}\left((\mathbf{x}_c\mathbf{x}_c^\top)(\mathbf{x}_c\mathbf{x}_c^\top)\right) = (\mathbf{x}_c^\top\mathbf{x}_c)\operatorname{tr}(\mathbf{x}_c\mathbf{x}_c^\top) = (\mathbf{x}_c^\top\mathbf{x}_c)^2 = (\mathbf{x}^\top H\mathbf{x})^2.$$
Extrayendo la raíz cuadrada (dado que $\mathbf{x}^\top H\mathbf{x} = \|\mathbf{x}_c\|_2^2 > 0$):
$$\sqrt{\operatorname{tr}(K_XHK_XH)} = \mathbf{x}^\top H\mathbf{x}.$$
De manera idéntica para $\mathbf{y}_c$:
$$\sqrt{\operatorname{tr}(K_YHK_YH)} = \mathbf{y}^\top H\mathbf{y}.$$

Sustituyendo numerador y denominador en la expresión de alineamiento:

$$\rho_{\text{RKHS}}(K_X, K_Y) = \frac{(\mathbf{x}^\top H\mathbf{y})^2}{(\mathbf{x}^\top H\mathbf{x})(\mathbf{y}^\top H\mathbf{y})} = \left(\frac{\mathbf{x}^\top H\mathbf{y}}{\sqrt{(\mathbf{x}^\top H\mathbf{x})(\mathbf{y}^\top H\mathbf{y})}}\right)^2.$$

Identificando la formulación matricial del coeficiente de Pearson muestral obtenida en el Punto 3.1:

$$\hat{\rho}_{XY} = \frac{\mathbf{x}^\top H\mathbf{y}}{\sqrt{(\mathbf{x}^\top H\mathbf{x})(\mathbf{y}^\top H\mathbf{y})}},$$

se concluye directamente:

$$\boxed{\rho_{\text{RKHS}}(K_X, K_Y) = \hat{\rho}_{XY}^2.} \quad \blacksquare$$

Explicación Teórica de la Pérdida del Signo

La pérdida del signo ocurre por una razón matemática y una razón geométrica directa:

a) **Razón algebraica (El cuadrado):** Como demostramos en el paso anterior, el alineamiento en RKHS equivale al coeficiente de Pearson al cuadrado:

$$\rho_{\text{RKHS}} = (\hat{\rho}_{XY})^2.$$

Dado que el cuadrado de cualquier número real es no negativo, una correlación directa perfecta ($\hat{\rho}_{XY} = +1$) y una correlación inversa perfecta ($\hat{\rho}_{XY} = -1$) dan exactamente el mismo resultado:

$$(+1)^2 = 1 \qquad \text{y} \qquad (-1)^2 = 1.$$

Por definición, $\rho_{\text{RKHS}} \geq 0$, lo que anula de forma automática cualquier signo negativo.

b) **Razón geométrica (Las matrices de Gram no ven direcciones):** El coeficiente de Pearson clásico mide la **dirección** de la recta (si es creciente o decreciente).

En cambio, las matrices de Gram K_X y K_Y solo miden la **similitud relativa entre pares de datos**. Si invertimos el sentido de la variable Y multiplicándola por -1 (haciendo $\mathbf{y} \to -\mathbf{y}$), el producto entre pares de muestras no cambia:

$$K_{-\mathbf{y}} = (-\mathbf{y})(-\mathbf{y})^\top = \mathbf{y}\mathbf{y}^\top = K_{\mathbf{y}}.$$

La matriz de similitudes de $-\mathbf{y}$ es idéntica a la de $\mathbf{y}$. Al kernel no le importa si la nube de puntos sube o baja en el plano cartesiano; solo registra qué tan cerca o lejos están los puntos entre sí.

c) **Interpretación estadística (R^2 vs. ρ):** Mientras que $\hat{\rho}_{XY} \in [-1, 1]$ indica la dirección y la fuerza de la relación, el índice de alineamiento $\rho_{\text{RKHS}} \in [0, 1]$ funciona exactamente como el coeficiente de determinación R^2 en regresión: cuantifica únicamente la **fuerza de la asociación lineal**, perdiendo el sentido de la pendiente.

Resultado Final: Alineamiento RKHS y Pérdida del Signo

$$\rho_{\text{RKHS}}(K_X, K_Y) = \frac{\operatorname{tr}(K_X H K_Y H)}{\sqrt{\operatorname{tr}(K_X H K_X H)\operatorname{tr}(K_Y H K_Y H)}}$$

Para kernels lineales con $P = Q = 1$, el alineamiento colapsa al cuadrado del coeficiente de Pearson:

$$\rho_{\text{RKHS}} = \hat{\rho}^2_{XY} \in [0, 1].$$

El signo se pierde porque las matrices de Gram miden similitud mutua entre observaciones y no la orientación de los ejes cartesianos ($K_{-\mathbf{y}} = K_{\mathbf{y}}$). Por lo tanto, el índice mide la magnitud o fuerza de la relación (R^2) y no su dirección.