Nombres: · Marlyn Nathalia Mora Riascos
· Hernan Jair Telpiz Cuaran

1 clasificación lineal y algoritmo del perceptrón.

$x \in \mathbb{R}^2 \Rightarrow$ clasificador

$y \in (-1, 1) \Rightarrow$ etiquetas

la predicción se obtiene mediante: $\hat{y} = \begin{cases} +1, & w^T x + b > 0 \\ -1, & w^T x + b \leq 0 \end{cases}$ $w \in \mathbb{R}^2, b \in \mathbb{R}$

1.1 Frontera de dicisión

$w = [1, 2]^T$, $b = -3$,
w_1 w_2

Ecuación de la recta: $w^T x + b = 0$

$Y = mx + b \Rightarrow 1x_1 + 2x_2 - 3 = 0$

$2x_2 = -1x + 3$

$x_2 = \frac{-1x}{2} + \frac{3}{2}$

$\boxed{x_2 = -0,5 + 1,5}$

ecuación de la recta

sabemos que:

$\begin{vmatrix} x_1 \\ x_2 \end{vmatrix}$ → eje horizontal X
→ eje vertical Y
→ equivalente a Y

Por ende se despeja x_2

- $x_1 = (0,0)$

reemplazando

$w^T x + b = w_1 x_1 + w_2 x_2 + b$

$1(0) + 2(0) + (-3) = \boxed{-3}$

$\Rightarrow \hat{y} = -1$

$\begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$

$x_2 = (1,0)$

$w_1 x_1 + w_2 x_2 + b$

$1(1) + (2(0) + (-3) = 1 + 0 - 3 = \boxed{-2}$

$\hat{y} = -1$

$x_3 = (2,7)$

$w_1 x_1 + w_2 x_2 + b$

$7(2) + 2(7) - 3 = 7$

$\hat{y} = +7$

$x_4 = (3,7)$

$w_1 x_1 + w_2 x_2 + b$

$7(3) + 2(7) - 3 = 2$

$\hat{y} = +7$

7,2 Actualización del perceptrón

$$w_{nuevo} = w + \eta y_i x_i \qquad b_{nuevo} = b + \eta y_i \qquad \eta > 0$$

para cuando una observación esta mal clasificada se considera la regla anterior (x_i, y_i)

marger de observaciones: m_i, nuevo $\Rightarrow m_i = y_i (w^T x_i + b)$

$$m_i + \eta(\|x_i\|_2^2 + 7)$$

Solución

$m_{i,nuevo} = y_i (w^T_{nuevo} x_i + b_{nuevo})$

sustituyendo

$m_{i,nuevo} = y_i((w + \eta y_i x_i)^T x_i + (b + \eta y_i))$

$(w + \eta y_i x_i)^T x_i = w^T x_i + \eta y_i x_i^T x_i$

$= w^T x_i + \eta y_i \|x_i\|_2^2$

Sustituimos en:

$$m_{i,nuevo} = y_i(w^T x_i + b + n y_i \|x_i\|_2^2 + n y_i)$$

$$m_{i,nuevo} = y_i((w^T x_i + b) + n y_i(\|x_i\|_2^2 + 1))$$

Por definición $m_i = y_i(w^T x_i + b)$

$$\Rightarrow m_{i,nuevo} = m_i + y_i(n y_i(\|x_i\|_2^2 + 1))$$

$$m_{i,nuevo} = m_i + n y_i^2(\|x_i\|_2^2 + 1)$$

evaluando $y_i = y_i^2 = 1$

$$\Rightarrow m_{i,nuevo} = m_i + n(\|x_i\|_2^2 + 1)$$

Explicación de la implicación

- Qué es la margen (m_i)? Es la distancia que hay entre cada ficha y la linea que se a dibyado en el piso., si la ficha esta del lado correcto es positivo + y si esta en lugar equivocado el margen es negativo −.

- Qué significa $m_{i,nuevo} = m_i +$ algo positivo.

como se suma una cantidad que siempre es mayor a cero $\eta > 0$ el resultado final del margen siempre va a ser mayor que el anterior.

- Al aplicar la regla de actualización del perseptron sobre una observación mal clasificada su margen aumenta porque $m_{i_n} = m_i + algo +$ ya que $\eta > 0$

7.3 $w^T = [0\ 0] \rightarrow w = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

$b = 0 \qquad \eta = 0,5 \qquad x = \begin{bmatrix} 2 \\ 7 \end{bmatrix} \qquad y = +7$

$\Rightarrow m_i = y_i(w^T x_i + b)$

$m_i = 7\left(\begin{bmatrix} 0 & 0 \end{bmatrix}\begin{bmatrix} 2 \\ 7 \end{bmatrix} + 0\right)$

$m_i = 7(0+0)+0 = \boxed{m_i = 0}$

como $m \leq 0 \Rightarrow$ frontera o clasificación incorrecta por ende se debe actualizar los parametros

$w_{nuevo} = w + \eta y_i x_i$

$w_{nuevo} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 0,5(7)\begin{bmatrix} 2 \\ 7 \end{bmatrix}$

$w_{nuevo} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 7 \\ 0,5 \end{bmatrix} = \begin{bmatrix} 7 \\ 0,5 \end{bmatrix}$

ahora b_{nuevo} (sesgo)

$b_{nuevo} = b + \eta y_i$

$b_{nuevo} = 0 + 0{,}5(7) \rightarrow \boxed{b_{nuevo} = 0{,}5}$

Calculamos el $mi_{nuevo} = y(w^T x_i + b)$

$Mi_{nuevo} = 7\left(\underset{1\times 2}{[7 \quad 0{,}5]}\underset{2\times 1}{\begin{bmatrix}2\\7\end{bmatrix}}\right) + 0{,}5$

$\underset{1\times 1}{\quad}$

$Mi_{nuevo} = (2*7)(0{,}5*7) + 0{,}5$

$\boxed{Mi_{nuevo} = 3}$ Como el margen inicial era cero se realizo la corrección

② Clasificación por los k vecinos más cercanos (k-NN)

observación nueva $q = (7,7)$

conjunto de entrenamiento:

observación	x_1	x_2	x_3	x_4	x_5
x_i	(0,0)	(7,0)	(3,7)	(0,3)	(7,7 7,7)
clase	A	A	B	B	B

Distancia Euclidiana $d(q, x_i)$

2.7 Calculo manual de distancias

$x_7 = (0,0)$ clase A

$\Rightarrow d(q, x_i) = \sqrt{(q_7 - x_{i,7})^2 + (q_2 - x_{i2})^2}$

$k=7$, $k=3$, $k=5$

$q_7 = 7$

$q_{12} = 7$

- distancias x_7 A

$d(q, x_i) = \sqrt{(7-0)^2 + (7-0)^2} = \sqrt{2} = \boxed{7,4742}$

- x_2 (7,0) A

$d(q, x) = \sqrt{(7-7)^2 + (7-0)^2} = \sqrt{7} = \boxed{7}$

- x_3 (3,7) B

$d(q, x) = \sqrt{(7-3)^2 + (7-7)^2} = \sqrt{4} = \boxed{2}$

- x_4 (0,3) B

$d(q, x) = \sqrt{(7-0)^2 + (7-3)^2} = \sqrt{5} = \boxed{2,236}$

- x_5 (7,7,7,7) B

$d(q, x) = \sqrt{(7-(7,7))^2 - (7-(7,7))^2} = \sqrt{0,02}$

$= \boxed{0,1414}$

Ordenar de mayor a menor

$k=1$

$k=3$

$k=5$.

Cercana	Punto	Distancia a q	clase
1	X_5	0,14	B
2	X_2	1,00	A
3	X_1	1,47	A
4	X_3	2,00	B
5	X_4	2,24	B

- Si $k=1 \Rightarrow X_5 \Rightarrow$ votos para A = 0
  B = 1

Ganador = clase B

Si $k=3 \Rightarrow X_5, X_2, X_1 \Rightarrow$ votos para A = 2
B = 1

Ganador clase A.

Si $k=5 \Rightarrow X_5, X_2, X_1, X_3 X_4$, Votos A = 2
B = 3

Ganador clase B

porque el valor de k puede cambiar la predicción?

El valor de k cambia la predicción porque modifica la escala del vecindario que el modelo considera para decidir.

(2.3) Al escoger un k muy pequeño sobreajustado (alta varianza), memoriza el ruido y genera fronteras irregulares.

- Cuando k muy grande: Subajuste (alto sesgo) y baja varianza, suaviza la frontera e ignora el patron local hasta colapzar a la clase mayorista.

- El modelo que generalizo mejor fue $k=5$ porque logró el mayor acierto en datos no vistos en test frente a entrenamiento logrando un balance ideal sesgo-varianza

- porque validación y no prueba?

Usando los datos de test produce fuga de datos ya que contaminas la evaluación al usar info de prueba para ajustar el modelo.

(3) $y = (0\ 0\ 0\ 0\ 1\ 1\ 1\ 1\ 1\ 1)$ Real

$\hat{y} = [0,1,0,0,1,0,1,1,0,1]$ Predicción

(3,1)

y Real — Predicho $\hat{y}$

0 0 → y negativo, $\hat{y}$ negativo = TN
0 1 → y negativo, $\hat{y}$ positivo = Fp
0 0 → y negativo, $\hat{y}$ negativo = TN
0 0 → y negativo, $\hat{y}$ negativo = TN
1 1 → y positivo, $\hat{y}$ positivo = Tp

7 0 → y+, ŷ−, = TN
7 7 → y+, ŷ+ = TP
7 7 → y+, ŷ+ = TP
7 0 → y+, ŷ− = FN
7 7 → y+, ŷ+ = TP

Conteo ⇒ TP = 4
TN = 3
FP = 7
FN = 2

matriz de confusión

Real/predicho	Predicho: 0(−)	predicho: 7(+)
Real 0(−)	TN = 3	FP = 7
Real 7(+)	FN = 2	TP = 4

⇒ $\begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix} = \begin{vmatrix} 3 & 7 \\ 2 & 4 \end{vmatrix}$

3,2

- $Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$, $Precisión = \frac{TP}{TP+FP}$

- $Recall = \frac{TP}{TP+FN}$, $F_7 = \frac{2\,Precisión\,Recall}{Precisión + Recall}$

Solución → Reemplazando los datos

$Accuracy = \frac{4+3}{4+3+7+2} = \frac{7}{70} = 0,7 \ (70\%)$

- accuracy evalua la proporción total de aciertos del clasificador en todo el conjunto de datos, asume que todas las clases y todos los tipos de error tienen la misma importancia.

- precisión: $\frac{4}{4+7}$ = 0,8 = 80%

- Evalua la confiabilidad de las predicciones positivas evita que el modelo de falsos positivos (cuando dice que es positivo pero en realidad es negativo)

- Recall: $\frac{4}{4+2}$ = 0,666 = 66,6%

Evalua la capacidad del modelo para encontrar todos los casos positivos reales, evitando dejar escapar falsos negativos.

- F1 - score = media armónica

$$F1 = \frac{2 * 0,8 * 0,666}{0,8 + 0,666} = 0,7268 \quad 72,68\%$$

Evalua el balance perfecto entre la presición y el Recall, es como un promedio que te dice si el modelo mantiene un buen equilibrio sin descuidar ninguna de las 2 cosas.

3,3 situaciones en las que accurary (exactitud) resulta engañosa

- Desbalance de clases
  * Diagnostico de enfermedades poco comunes donde el 99% de las muestras son sanas y el 1% son muestras de enfermo.

Hay un modelo peresozo que siempre dice no pasa nada puede tener 99% de aciertos porque el 99% de los casos reales son normales en la vida real eso no nos sirve porque falla por completo en detectar el unico 1% que verdaderamente importa

- Asimetria de costas, cuando equivocarse cuesta más que acertar.

para la exactitud equivocarse diciendo que alguien esta enfermo vale exactamente lo mismo que mandar a un enfermo a la casa sin tratamiento (falso negativo)

El problema es que un modelo con 95% de exactitud puede ser muy peligroso si ese 5% de errores se concentra en dejar ir a pasientes enfermos.